



INFORME EJECUTIVO

Sistema Predictivo de Riesgo Coronario

Madrid, Marzo 2026.

Scrum Master - **Gema Yébenes Caballero.**
Full-Stack & QA Lead - **Isabel Rodríguez Amor.**
ML & Optimization Engineer - **Paloma Gómez Saldaña.**
Project Manager - **Roberto Antonio Molero Losada.**

Resumen Ejecutivo

Este documento presenta los resultados del proyecto de Inteligencia Artificial orientado a la detección temprana del riesgo de enfermedad coronaria. A lo largo del proyecto se construyeron, compararon y refinaron múltiples modelos de predicción clínica. El equipo evaluó distintos algoritmos y estrategias de tratamiento de datos antes de seleccionar el modelo definitivo, priorizando en todo momento la seguridad del paciente.

918 Pacientes analizados <i>Conjunto de datos real</i>	12 Variables clínicas <i>Seleccionadas por calidad</i>	92 % Pacientes detectados <i>Sensibilidad (Recall)</i>	91,7 % Capacidad discriminatoria <i>Area bajo la curva (ROC-AUC)</i>
--	--	--	--

La prioridad clínica del proyecto fue minimizar los falsos negativos, es decir, reducir al máximo el riesgo de que un paciente enfermo reciba un diagnóstico negativo incorrecto. El modelo final cumple este objetivo con garantías sólidas.

1. El Problema y los Datos de Partida

1.1 Que se queria resolver

Las enfermedades del corazón constituyen una de las principales causas de mortalidad a nivel mundial. La detección temprana es crítica: cuanto antes se identifica un paciente en riesgo, mayores son las posibilidades de intervención exitosa. Este proyecto buscó entrenar un sistema capaz de predecir, a partir de datos clínicos rutinarios, la probabilidad de que un paciente padece una cardiopatía coronaria.

1.2 Los datos disponibles

Se partió de un conjunto de 918 registros de pacientes, cada uno descrito por un conjunto de variables clínicas estándar. Antes de entrenar cualquier modelo, se realizó un análisis exploratorio exhaustivo, denominado en el ámbito técnico EDA (Análisis Exploratorio de Datos, del Exploratory Data Analysis), para garantizar la calidad de la información.

El análisis exploratorio reveló los siguientes aspectos relevantes:

- El conjunto de datos está compuesto por 918 pacientes y 12 variables clínicas originales, incluyendo datos demográficos, signos vitales y resultados de electrocardiograma.

- La distribución entre pacientes sanos y enfermos es equilibrada: aproximadamente el 55 % de los registros corresponde a pacientes con enfermedad cardíaca confirmada y el 45 % restante a pacientes sanos.
- No se detectaron valores ausentes en el sentido estricto, pero sí se identificaron valores fisiológicamente imposibles en la variable Colesterol y en la Presión Arterial en Reposo: registros con valor cero.

1.3 El debate sobre el Colesterol: una decisión clave del equipo

Durante el análisis inicial, la variable Colesterol presentaba 172 registros con valor cero, lo que supone aproximadamente el 18 % del conjunto de datos. Un nivel de colesterol de cero es biológicamente imposible, por lo que estos registros se consideraron datos erróneos o no recogidos.

Ante esta situación, el equipo evaluó dos estrategias posibles:

- Imputación de la mediana: sustituir los valores cero por la mediana del resto del conjunto para mantener el 100 % de los registros. Esta vía fue explorada en uno de los modelos experimentales.
- Exclusión de la variable: eliminar el colesterol del entrenamiento para no introducir un 18 % de datos artificialmente generados que podrían sesgar el modelo.

Tras evaluar los resultados obtenidos con ambas estrategias, el equipo tomó la decisión definitiva de excluir el colesterol del modelo final. Los experimentos demostraron que la variable, una vez imputada, no aportaba una mejora significativa en la capacidad predictiva, mientras que su inclusión introducía una fuente de ruido que comprometía la robustez del sistema. Esta decisión quedó respaldada por los datos.

1.4 Variables seleccionadas para el entrenamiento

Tras el análisis, se retuvieron 12 variables de alta fiabilidad y relevancia clínica demostrada:

- **Demograficas:** Edad y Sexo
- **Signos vitales:** Frecuencia cardíaca máxima (Max HR) y Glucosa en ayunas (Fasting BS)
- **Indicadores de esfuerzo:** Angina inducida por el ejercicio (Exercise Angina)
- **Dolor torácico:** Tipo de dolor torácico, codificado en cuatro categorías: ASY (asintomático), ATA (angina atípica), NAP (dolor no anginoso) y TA (angina típica)
- **Hallazgos del ECG:** Pendiente del segmento ST en el electrocardiograma (ECG): ascendente (Up), plana (Flat) o descendente (Down)

2. Metodología: El Recorrido por los Modelos

El equipo adoptó un enfoque iterativo: se entrenaron y evaluaron varios algoritmos de forma progresiva, aprendiendo de las limitaciones de cada uno para tomar decisiones más informadas en la siguiente fase. A continuación se describe ese recorrido.

2.1 Fase 1 — Regresión Logística: establecer una referencia

El primer modelo entrenado fue una Regresión Logística (Logistic Regression). Se trata de un algoritmo estadístico clásico, ampliamente utilizado en medicina, que estima la probabilidad de pertenencia a una categoría: en este caso, enfermo o sano.

Para asegurar que los resultados no dependieran de una división concreta de los datos, se empleó Validación Cruzada con cinco particiones (5-Fold Cross-Validation): el conjunto se dividió en cinco bloques y el modelo se entrenó y evaluó cinco veces, usando cada vez un bloque diferente como conjunto de prueba.

Resultado de la Regresión Logística

- Área bajo la curva (ROC-AUC): 91,15 % — resultado sólido que confirmó la viabilidad del enfoque.
- Limitación identificada: el modelo presentaba dificultades para capturar relaciones complejas y no lineales entre variables como el tipo de dolor torácico y la pendiente del segmento ST del ECG.
- Conclusión: útil como referencia, pero insuficiente para los objetivos de sensibilidad clínica del proyecto.

2.2 Fase 2 — K Vecinos más Cercanos (K-NN): la estrategia de la similitud

En paralelo se exploró el algoritmo K-NN (K-Nearest Neighbors, o K Vecinos más Cercanos). Este método clasifica a un paciente nuevo buscando, en el historial de pacientes conocidos, aquellos con un perfil clínico más parecido y tomando una decisión por votación de la mayoría.

En esta fase se optó por mantener el colesterol en el conjunto de datos, imputando los valores cero con la mediana del grupo. El modelo se configuró con 7 vecinos ($k=7$), valor elegido para reducir el efecto del ruido.

Resultado del modelo K Vecinos más Cercanos

- Exactitud (Accuracy): 85 % — resultado aceptable en términos absolutos.
- Sensibilidad (Recall): 81 % — el modelo identificaba correctamente solo 81 de cada 100 pacientes enfermos.

- Limitación crítica: la sensibilidad era inferior a los objetivos clínicos del proyecto. La inclusión del colesterol imputado no aportó una ventaja significativa.
- Conclusión: descartado por no alcanzar el umbral de seguridad clínica requerido.

2.3 Fase 3 — Bosque Aleatorio: mayor potencia predictiva

La tercera fase introdujo el Bosque Aleatorio (Random Forest), un algoritmo de la familia de los modelos de ensamble. En lugar de construir un único árbol de decisión, este método combina los resultados de cientos de árboles independientes para producir una predicción final más robusta y precisa.

El problema del sobreajuste y como se corrigió

Al entrenar el Bosque Aleatorio sin restricciones, se detectó un problema crítico: el modelo aprendía de memoria los datos de entrenamiento, pero fallaba al enfrentarse a pacientes nuevos. Este fenómeno se denomina sobreajuste (overfitting).

Sin regularización — Problema	Con regularización — Solución
Exactitud entrenamiento: ~99 % (memorización)	Exactitud entrenamiento: 87,47 %
Exactitud datos nuevos: ~81 % (fallo real)	Exactitud datos nuevos: 87,50 %
Brecha (Gap): 18 % Inaceptable	Brecha (Gap): 0,03 % Generalización perfecta

La solución fue aplicar regularización mediante el parámetro de profundidad máxima (max_depth = 5), que limita la complejidad de cada árbol individual e impide que el modelo memorice patrones en lugar de aprenderlos.

2.4 Decisión final del equipo

Tras evaluar los resultados de los tres enfoques, el equipo alcanzó una conclusión unánime basada en criterios clínicos y estadísticos:

El Bosque Aleatorio con regularización (max_depth = 5), entrenado con las 12 variables seleccionadas y sin la variable Colesterol, es el modelo que mejor cumple los objetivos del proyecto. Ofrece la mayor sensibilidad, la mejor generalización y los fundamentos más sólidos para su uso como herramienta de apoyo al diagnóstico clínico. La eliminación del colesterol, lejos de penalizar el rendimiento, contribuyó a la estabilidad y fiabilidad del sistema.

2.5 Comparativa global entre modelos

La siguiente tabla resume el rendimiento de todos los modelos explorados y justifica la elección final:

Algoritmo	Recall	Exactitud	ROC-AUC	Valoración
Regresión Logística	—	—	91,15 %	Buen punto de partida. Sin capacidad para relaciones no lineales.
K Vecinos más Cercanos (K-NN)	81 %	85 %	—	Sensibilidad insuficiente para uso clínico. Descartado.
Bosque Aleatorio sin regularización	Alta *	81 %	—	Sobreajuste severo (brecha del 18 %). Descartado.
Bosque Aleatorio con regularización — MODELO FINAL	92,16 %	87,50 %	91,68 %	Brecha < 0,1 %. Máxima seguridad clínica. Seleccionado.

* En el Bosque Aleatorio sin regularización, la exactitud en entrenamiento era artificialmente alta (~99 %) por memorización, no por aprendizaje real.

3. Resultados del Modelo Final

3.1 Métricas de rendimiento

Los resultados presentados a continuación fueron obtenidos evaluando el modelo definitivo sobre datos que nunca había procesado durante el entrenamiento:

Métrica	Resultado	Significado Clínico
Exactitude (Accuracy)	87,50 %	Precisión global de cada diagnóstico emitido.
Precisión (Precision)	86,24 %	Porcentaje de alarmas positivas que corresponden a un paciente realmente enfermo.
Sensibilidad (Recall)	92,16 %	Porcentaje de enfermos detectados correctamente. Nuestra métrica prioritaria.
Puntuación F1 (F1-Score)	89,10 %	Equilibrio óptimo entre falsas alarmas y casos no detectados.
Área bajo la curva (ROC-AUC)	91,68 %	Capacidad global de discriminar entre pacientes sanos y enfermos.

Interpretación para la práctica clínica

- De cada 100 pacientes enfermos, el modelo identifica correctamente a 92 de ellos como positivos, dejando únicamente 8 sin diagnóstico de alerta.
- De cada 100 alarmas que emite el sistema, 86 corresponden a pacientes realmente enfermos. Las 14 restantes son falsas alarmas que un profesional sanitario puede descartar con pruebas adicionales.
- En un entorno clínico, es preferible un exceso de alarmas verificables a dejar casos graves sin detectar.

4. Interpretación Clínica: Que aprendió el modelo

Uno de los aspectos más valiosos del modelo seleccionado es su transparencia. Mediante el análisis de importancia de variables (Feature Importance), es posible conocer en qué señales clínicas se basa el sistema para tomar cada decisión. Los resultados son coherentes con la evidencia médica establecida:

#	Variable clínica	Peso en el modelo
1	Pendiente del ST ascendente (ST_Slope_Up) <i>Principal indicador de salud cardíaca. Su presencia reduce significativamente el riesgo estimado.</i>	~25 % de peso
2	Pendiente del ST plana (ST_Slope_Flat) <i>Principal indicador de riesgo coronario. Su presencia eleva significativamente la probabilidad de enfermedad.</i>	~20 % de peso
3	Dolore toracico asintomatico (CP_ASY) <i>La ausencia de síntomas clínicos se asocia frecuentemente a episodios violentos de cardiopatía isquémica.</i>	Variable relevante

Estos hallazgos no son arbitrarios: el modelo reproduce de forma autónoma el conocimiento médico establecido en la literatura cardiológica, lo que refuerza su credibilidad y su potencial utilidad como herramienta de apoyo a la decisión clínica.

Adicionalmente, el proyecto cuenta con una interfaz de usuario que permite introducir los parámetros clínicos de un paciente y obtener una predicción en tiempo real, facilitando la integración del sistema en un flujo de trabajo asistencial.

5. Conclusiones y Valor del Proyecto

Logros principales del proyecto

- Se evaluaron múltiples algoritmos: Regresión Logística, Vecinos más Cercanos y Bosque Aleatorio, seleccionando el modelo con mejor equilibrio entre precisión y seguridad clínica.
- Se analizó en detalle el impacto del colesterol como variable predictiva. Tras experimentar con imputación de datos, el equipo decidió excluirla por no aportar mejoras significativas y si introducir ruido artificial.
- Se identificó y corrigió el sobreajuste, garantizando que el modelo generalice correctamente ante cualquier paciente nuevo.
- El modelo final detecta el 92 % de los pacientes con riesgo coronario real, con un área bajo la curva del 91,68 %.
- Las variables más influyentes son coherentes con la evidencia clínica, lo que aporta interpretabilidad y confianza al sistema.
- El proyecto cuenta con una interfaz funcional que permite al equipo clínico utilizar el sistema de forma directa e intuitiva.

5.1 Reflexión sobre el enfoque adoptado

Este proyecto demuestra que el rigor en la preparación de los datos y el control del sobreajuste tienen más impacto en los resultados finales que la mera complejidad del algoritmo elegido. El recorrido por distintos modelos no fue un camino lineal: cada experimento aportó aprendizajes concretos que condujeron, de forma fundamentada, a la solución definitiva.

El modelo entregado no pretende sustituir el criterio clínico del profesional sanitario, sino actuar como una segunda opinión cuantitativa, capaz de alertar sobre casos de riesgo que podrían pasar desapercibidos en una revisión rutinaria.

5.2 Posibles líneas de mejora futuras

- Ampliar el conjunto de datos con registros de otras poblaciones para mejorar la generalización geográfica y demográfica del sistema.
- Explorar algoritmos de mayor potencia como Potenciación del Gradiente (Gradient Boosting: XG Boost o Light GBM) con validación cruzada completa.
- Reevaluar la inclusión del colesterol si en el futuro se dispone de registros validados y completos, libres de valores erróneos.
- Continuar el desarrollo de la interfaz de usuario para una integración más profunda en entornos de gestión clínica.