



Informe de Proyecto Evaluado Gema

Sistema Predictivo de Riesgo Coronario

Modelo Final: Random Forest con Regularización (`max_depth=5`)

Métrica Objetivo: Maximizar Recall (Sensibilidad) para Seguridad Clínica.

1. Análisis Exploratorio y Selección Crítica de Variables (EDA)

En la fase inicial, tomamos una decisión fundamental: **priorizar la calidad del dato sobre la cantidad**. ### El desafío del Colesterol

Detectamos que la variable `Cholesterol` presentaba **172 registros con valor 0**. Dado que un colesterol de cero es biológicamente imposible, decidimos **excluirla del entrenamiento**. Aunque podíamos haber imputado la media, consideramos que introducir un 18% de datos "inventados" añadiría un ruido innecesario que sesgaría las predicciones del modelo.

Variables Finales de Entrenamiento (Feature Selection)

Seleccionamos las siguientes 12 variables por su alta fidelidad y relevancia clínica:

- **Demográficas:** `Age` , `Sex` .
 - **Signos Vitales:** `MaxHR` (Frecuencia Cardíaca Máxima), `FastingBS` (Azúcar en ayunas).
 - **Indicadores de Esfuerzo:** `ExerciseAngina` (Angina inducida por ejercicio).
 - **Categorías de Dolor Torácico (Dummies):** `CP_ASY` , `CP_ATA` , `CP_NAP` , `CP_TA` .
 - **Hallazgos del ECG (Dummies):** `ST_Slope_Flat` , `ST_Slope_Up` , `ST_Slope_Down` .
-

2. Fase 1: Regresión Logística (Modelo Base)

Iniciamos con la Regresión Logística para establecer un punto de comparación sólido.

- **Técnica:** Aplicamos **Validación Cruzada (K-Fold = 5)** para asegurar que los resultados no fueran producto del azar.
 - **Resultado:** Obtuvimos un **ROC-AUC de 0.9115**.
 - **Comportamiento:** Mostró ser un modelo estable, pero presentaba limitaciones para capturar relaciones no lineales complejas entre variables como el tipo de dolor y la pendiente del ST.
-

3. Fase 2: Random Forest y Gestión del Overfitting

Pasamos a un modelo de ensamble (Random Forest) para mejorar la capacidad predictiva.

El problema detectado: Overfitting severo

Al entrenar el Random Forest inicial sin restricciones, observamos una brecha (gap) inaceptable:

- **Precisión Entrenamiento:** ~99% (El modelo memorizó los datos).
- **Precisión Prueba:** ~81% (El modelo fallaba con datos nuevos).
- **Diferencia:** 18%. Esto indicaba un claro sobreajuste.

La solución: Ajuste de Hiperparámetros

Para corregir esto, aplicamos **hiperparámetros de control**, específicamente limitando la profundidad del árbol a `max_depth=5`.

- **Resultado del ajuste:**
 - RF Entrenamiento: **0.8747**
 - RF Prueba: **0.8750**
 - **Brecha (Gap): 0.0003.**
 - **Conclusión:** Logramos una generalización casi perfecta. El modelo ahora es robusto y fiable para cualquier paciente nuevo.
-

4. Evaluación Final de Métricas (Modelo Ganador)

Tras el ajuste, el **Random Forest (`max_depth=5`)** se consolida como el mejor modelo con los siguientes resultados en el conjunto de prueba:

Métrica	Resultado	Significado Clínico
Accuracy	0.8750	Precisión global del diagnóstico.
Precision	0.8624	Seguridad de que un "positivo" es realmente un enfermo.
Recall (Sensibilidad)	0.9216	Nuestra prioridad: Detectamos al 92% de los enfermos.
F1-Score	0.8910	Balance óptimo entre falsos positivos y negativos.
ROC-AUC	0.9168	Capacidad superior de distinción frente a la Regresión Logística.

5. Interpretación Clínica: ¿Qué detectó el modelo?

Gracias al análisis de **Importancia de Variables (Feature Importance)**, confirmamos que el modelo basa su éxito en criterios médicos lógicos:

1. **ST_Slope_Up:** Es el predictor de salud más potente (25% de peso).
2. **ST_Slope_Flat:** El principal indicador de riesgo (20% de peso).
3. **CP_ASY:** El dolor asintomático es la categoría de dolor más relevante para el diagnóstico.

6. Conclusión

Este proyecto demuestra que la **calidad de la selección de variables** y el **control del overfitting** son más importantes que la complejidad del algoritmo. Hemos entregado un modelo que no solo supera en potencia a la Regresión Logística, sino que garantiza la seguridad del paciente con un **Recall del 92%**, minimizando el riesgo de dejar a un paciente enfermo sin diagnóstico.