

Informe Final de Predicción de Riesgo Coronario

Modelo: K-Nearest Neighbors (K-NN)

Metodología: Integridad de Datos y Escalado por Distancias

1. Introducción y Análisis Exploratorio (EDA)

Hemos analizado un dataset de **918 pacientes**. El objetivo principal fue identificar patrones que permitan al algoritmo **K-NN** clasificar la salud cardiovascular con alta precisión.

- **Balance de datos:** El 55.3% presentan enfermedad y el 44.7% están sanos, lo que permite un aprendizaje equilibrado sin sesgos.
- **Hallazgo crítico:** Detectamos 172 valores "0" en colesterol y 1 en presión arterial. Identificamos estos valores como errores biológicos que debían ser tratados para no distorsionar las "distancias" del modelo K-NN.

2. Estrategia de Preprocesamiento (Integridad Total)

A diferencia de otros enfoques que descartan datos, **hemos optado por salvar la información:**

- **Imputación por Grupos:** Sustituimos los ceros de colesterol por la **mediana** calculada específicamente para cada grupo (sanos vs. enfermos). Esto mantiene la señal clínica real.
- **Escalado Min-Max:** Transformamos todas las variables numéricas al rango [0, 1]. Esto es vital para K-NN, asegurando que la Edad y el Colesterol pesen lo mismo en el cálculo de cercanía. [cite: 2026-02-27]
- **Codificación:** Aplicamos *Label Encoding* para sexo/angina y *One-Hot Encoding* para tipos de dolor de pecho (CP_ASY, etc.), convirtiendo categorías en vectores matemáticos.

3. Evaluación del Modelo K-NN

El modelo fue entrenado con un split 80/20 y una configuración de **k=7 vecinos**. Los resultados obtenidos son:

- **Accuracy Global: 85%**
- **Precisión (Clase 1): 92%** *Este es nuestro dato estrella: cuando el modelo predice enfermedad, tiene un 92% de acierto, minimizando los falsos positivos.*
- **Recall (Sensibilidad): 81%** *Detectamos a 8 de cada 10 enfermos manteniendo todas las variables originales.*

4. Conclusión Final

Nuestro proyecto demuestra que la **integridad de los datos** (evitando eliminar columnas) combinada con un **escalado riguroso** permite obtener un modelo altamente confiable. La precisión del 92% garantiza un sistema de apoyo al diagnóstico que evita pruebas innecesarias en pacientes sanos.