

INFORME TÉCNICO

Sistema Inteligente para la Detección de

Insuficiencia Cardíaca y Enfermedad Coronaria

Heart Failure Prediction Dataset — Modelo XGBoost con Optimización Bayesiana

Madrid, marzo de 2026

1. Contexto Clínico y Curación de Datos

El conjunto de datos Heart Failure Prediction comprende registros clínicos de 918 pacientes, incorporando variables biomédicas fundamentales tales como edad, sexo, presión arterial en reposo, niveles de colesterol sérico, frecuencia cardíaca máxima y hallazgos electrocardiográficos. El objetivo del sistema es clasificar de manera binaria la presencia o ausencia de enfermedad cardíaca (HeartDisease: 0 = Sano, 1 = Enfermo).

Durante la fase de exploración inicial, se identificaron inconsistencias fisiológicamente imposibles en dos variables de alta relevancia clínica:

- Colesterol (Cholesterol): se detectaron registros con valor 0 mg/dl, lo cual resulta biológicamente inviable, ya que el colesterol sérico siempre presenta valores mensurables en organismos vivos.
- Presión Arterial en Reposo (RestingBP): de forma análoga, se encontró un registro con valor 0 mmHg, incompatible con la vida.

Para corregir estas anomalías sin distorsionar la distribución estadística del conjunto, se sustituyeron los valores cero por valores nulos (NaN) y, posteriormente, se aplicó la técnica de imputación mediante la mediana utilizando SimpleImputer de la librería Scikit-Learn. La elección de la mediana sobre la media responde a su robustez frente a valores extremos (outliers): al no verse influenciada por valores atípicos en los extremos de la distribución, garantiza que el modelo de XGBoost aprenda de valores fisiológicamente plausibles y representativos de la población estudiada.

2. Codificación de Sintomatología Crítica

Los algoritmos de Machine Learning, por su naturaleza matemática, operan exclusivamente sobre datos cuantitativos. El conjunto de datos contenía tres variables categóricas nominales de alta relevancia clínica que requirieron transformación:

2.1 Tipo de Dolor Torácico (ChestPainType)

Esta variable categoriza la sintomatología en cuatro presentaciones clínicas distintas. Se aplicó One-Hot Encoding mediante `pd.get_dummies()` de Pandas, generando cuatro columnas binarias independientes. Este enfoque resulta indispensable porque las categorías no poseen orden jerárquico, y una codificación ordinal implicaría erróneamente que un tipo de dolor es matemáticamente superior a otro.

La categoría ChestPainType_ASY (Asymptomatic) adquiere especial relevancia médica: paradójicamente, la ausencia de dolor torácico constituye el predictor más peligroso de infarto silencioso. Los pacientes asintomáticos no perciben señales de alerta, lo que retrasa la búsqueda de atención médica y agrava el pronóstico. El modelo aprendió a identificar este patrón contraintuitivo como factor de alto riesgo.

2.2 Pendiente del Segmento ST (ST_Slope)

El comportamiento del segmento ST durante el electrocardiograma de esfuerzo es un indicador directo del estado de perfusión miocárdica. Mediante One-Hot Encoding se generaron tres variables binarias:

- ST_Slope_Down (descendente): patrón asociado con isquemia miocárdica activa y mayor probabilidad de enfermedad coronaria significativa.
- ST_Slope_Flat (plana): indicador de riesgo cardíaco intermedio-alto, frecuentemente vinculado a estenosis coronaria.
- ST_Slope_Up (ascendente): considerado fisiológicamente normal, asociado a menor riesgo de cardiopatía isquémica.

2.3 Electrocardiograma en Reposo (RestingECG)

De manera equivalente, los hallazgos electrocardiográficos en reposo fueron codificados en tres indicadores binarios: RestingECG_Normal (sin anomalías), RestingECG_LVH (hipertrofia ventricular izquierda, sugestiva de cardiopatía hipertensiva crónica) y RestingECG_ST (anomalía en la onda ST-T, señal potencial de isquemia o lesión miocárdica).

3. Abordaje del Desbalance de Clases y Detección de Patologías

En el ámbito de la medicina preventiva, el desbalance de clases constituye uno de los desafíos más críticos del aprendizaje automático. El conjunto de datos presentaba una distribución asimétrica entre pacientes sanos (clase 0) y pacientes con enfermedad cardíaca (clase 1). Este fenómeno es inherente a los estudios epidemiológicos: en la población general, los individuos sanos siempre superan en número a los enfermos diagnosticados.

Si no se corrige este desequilibrio, el algoritmo de XGBoost tiende a optimizar su rendimiento prediciendo mayoritariamente la clase dominante (sanos), resultando en un modelo con alta precisión aparente pero incapaz de detectar los casos de riesgo, que son precisamente los de mayor valor clínico.

Para solventar esta limitación se aplicó SMOTE (Synthetic Minority Oversampling Technique) de la librería imbalanced-learn. El algoritmo genera registros sintéticos de pacientes enfermos interpolando entre casos reales existentes en el espacio de características, sin duplicar simplemente los mismos registros. Este proceso se aplicó exclusivamente sobre el conjunto de entrenamiento (X_train), preservando la distribución natural en el conjunto de prueba (X_test) para garantizar una evaluación realista del rendimiento del sistema.

4. Optimización con Enfoque en la Supervivencia (Recall)

El proceso de optimización de hiperparámetros se ejecutó en dos etapas secuenciales mediante búsqueda bayesiana con la librería Optuna, configurada con un límite de 200 iteraciones y mecanismo de parada temprana (Early Stopping) activado tras 20 intentos consecutivos sin mejora.

4.1 Primera Optimización: F1-Score

La primera búsqueda, orientada a maximizar el F1-Score, exploró el espacio de hiperparámetros {n_estimators, max_depth, learning_rate, subsample, colsample_bytree, reg_alpha, reg_lambda}, alcanzando un F1 promedio de 0.88 en validación cruzada estratificada de 5 pliegues.

4.2 Segunda Optimización: Recall (Métrica Objetivo Final)

La segunda búsqueda priorizó explícitamente el Recall (Sensibilidad) como métrica de optimización. Esta decisión estratégica responde a una premisa fundamental de la cardiología preventiva: el costo asimétrico de los errores de clasificación.

Un Falso Negativo (clasificar como sano a un paciente enfermo) en el contexto cardíaco puede resultar fatal: el paciente es dado de alta sin diagnóstico, sin tratamiento y sin seguimiento, incrementando exponencialmente el riesgo de infarto agudo de miocardio. Por el contrario, un Falso Positivo (alertar sobre riesgo en un paciente sano) genera únicamente pruebas diagnósticas adicionales innecesarias, un coste clínico y económico asumible. El sistema fue diseñado como un escudo de detección que prioriza no dejar escapar ningún caso de riesgo real.

Los mejores hiperparámetros identificados por Optuna para el modelo orientado a Recall fueron:

Hiperparámetro	Valor Óptimo
n_estimators	369
max_depth	3 (limitado manualmente)
learning_rate	0.2229
subsample	0.8813
colsample_bytree	0.8994
reg_alpha (L1)	1.2819
reg_lambda (L2)	7.7542
min_child_weight	5 (fijo)
gamma	1 (fijo)

5. Ajuste del Umbral Clínico (0.4)

Los clasificadores binarios estándar utilizan un umbral de decisión de 0.5: si la probabilidad estimada de pertenecer a la clase positiva supera el 50%, el paciente se clasifica como enfermo. Sin embargo, en cardiología preventiva, este umbral estándar resulta insuficientemente sensible.

Se realizó un análisis comparativo del impacto del umbral sobre las métricas clínicas:

Umbral	Recall Enfermo	F1-Score
0.5 (estándar)	0.8505	0.8792
0.4 (seleccionado)	0.8692	0.8774
0.3	0.9159	0.8829
0.2	0.9439	0.8745

Se seleccionó el umbral de 0.4 por representar el equilibrio óptimo entre sensibilidad clínica y mantenimiento de la capacidad discriminativa general del sistema ($F1 = 0.8774$). Con este umbral, el sistema activa la alerta de riesgo cuando la probabilidad estimada de enfermedad cardíaca alcanza o supera el 40%, lo que refleja el principio de medicina preventiva: es preferible derivar a un paciente sano a pruebas adicionales (Falso Positivo controlado) que omitir el diagnóstico de un enfermo real.

6. Robustez y Seguridad del Diagnóstico

6.1 Control del Sobreajuste mediante Regularización

La configuración final incorpora un mecanismo multicapa de regularización para prevenir el sobreajuste (overfitting), garantizando que el modelo generalice correctamente ante nuevos pacientes no vistos durante el entrenamiento:

- `max_depth = 3`: limita la profundidad máxima de cada árbol de decisión, impidiendo que el modelo memorice patrones específicos del conjunto de entrenamiento en lugar de aprender reglas generalizables.
- `gamma = 1`: establece un umbral mínimo de reducción de pérdida para ejecutar nuevas particiones en los nodos del árbol, actuando como poda preventiva.
- `min_child_weight = 5`: exige un peso mínimo de 5 muestras para crear nuevos nodos hoja, evitando divisiones basadas en ruido estadístico.
- `reg_alpha (L1)` y `reg_lambda (L2)`: penalizan la complejidad excesiva de los pesos del modelo, promoviendo soluciones más simples y generalizables.

Los resultados de la evaluación de sobreajuste confirmaron el éxito de estas medidas:

Métrica	Valor
Accuracy en Entrenamiento (Train)	0.9115
Accuracy en Prueba (Test)	0.8696
Diferencia (Train - Test)	0.0419

Una diferencia de 0.0419 entre el rendimiento en entrenamiento y prueba confirma que el modelo no memorizó los datos de entrenamiento y es capaz de generalizar correctamente a nuevos pacientes.

6.2 Validación Cruzada Estratificada

Se implementó Validación Cruzada Estratificada con 5 pliegues (StratifiedKFold, shuffle=True, random_state=42) sobre el conjunto de datos completo. La estratificación garantiza que la proporción entre pacientes sanos y enfermos se mantenga constante en cada partición, produciendo una estimación de rendimiento estadísticamente robusta e independiente de sesgos de muestreo:

Métrica de Validación Cruzada	Valor
F1 Fold 1	0.9109
F1 Fold 2	0.8867
F1 Fold 3	0.8545
F1 Fold 4	0.9082
F1 Fold 5	0.8638
F1 Media	0.8848
Desviación Estándar	0.0228

Una desviación estándar de 0.0228 confirma que el rendimiento del modelo es altamente estable y consistente independientemente de la partición de datos utilizada, validando su fiabilidad para cualquier perfil de paciente.

7. Métricas Finales del Modelo

Las métricas obtenidas con el modelo final (best_model_recall, umbral 0.4, entrenado con SMOTE) sobre el conjunto de prueba no balanceado (184 pacientes, distribución real) fueron:

Clase	Precisión	Recall	F1-Score	Soporte
Sano (0)	0.85	0.86	0.85	77
Enfermo (1)	0.90	0.89	0.89	107
Accuracy			0.88	184
Macro Avg	0.87	0.87	0.87	184

El Recall de 0.89 para la clase Enfermo indica que el sistema detecta correctamente el 89% de los pacientes con enfermedad cardíaca, lo que se traduce en que, de cada 100 pacientes enfermos, solo 11 permanecerían sin diagnóstico. La precisión de 0.90 confirma, además, que el 90% de las alertas generadas por el sistema corresponden a pacientes realmente enfermos, minimizando las alarmas injustificadas.

8. Puesta en Producción del Modelo Maestro

Una vez validada la robustez del sistema mediante validación cruzada estratificada y confirmado su rendimiento sobre datos no vistos, el modelo maestro fue exportado mediante la librería `joblib`:

```
joblib.dump(best_model_recall, '../data/model_R.pkl')
```

El archivo `model_R.pkl` encapsula la totalidad del modelo entrenado, incluyendo los pesos de los 369 árboles de decisión, la configuración de hiperparámetros y el estado interno del algoritmo. Este formato de serialización permite la integración directa del sistema en entornos de producción clínica mediante una única instrucción de carga:

```
modelo = joblib.load('model_R.pkl')
```

El sistema resultante es directamente integrable en plataformas de apoyo al diagnóstico médico, sistemas de historia clínica electrónica (HCE) o interfaces de triaje hospitalario, proporcionando una evaluación de riesgo cardíaco en tiempo real para cualquier paciente que presente los 11 indicadores biomédicos contemplados en el modelo.

9. Conclusión

El presente trabajo ha demostrado que es posible construir un sistema de detección precoz de enfermedad cardíaca con alta sensibilidad clínica mediante la combinación sistemática de técnicas de preprocesamiento de datos médicos, codificación de sintomatología crítica, balanceo de clases, optimización bayesiana de hiperparámetros y ajuste de umbral de decisión orientado a la prevención.

El modelo final alcanza un Recall del 89% para la detección de enfermedad cardíaca con una accuracy global del 88%, avalado por una F1 media de 0.8848 en validación cruzada estratificada de 5 pliegues con una desviación estándar de apenas 0.023, confirmando su estabilidad y generalización ante perfiles de pacientes diversos.

El objetivo no es únicamente técnico: cada porcentaje de mejora en la sensibilidad del sistema representa pacientes reales que reciben diagnóstico temprano, tratamiento oportuno y, en última instancia, una mayor probabilidad de supervivencia. El sistema ha sido diseñado, optimizado y validado con ese principio como guía fundamental.